

Непараметрическая регрессия

Цели работы:

- 1) практика первичных навыков обработки данных: нормализация, One-Hot преобразование;
- 2) сведение задачи классификации к задаче непараметрической регрессии;
- 3) реализация решения задачи непараметрической регрессии ядерным сглаживанием Надарая Ватсона;
- 4) практика наивного способа настройки и анализа гиперпараметров модели, решающей задачу непараметрической регрессии.

Набор данных

Выберите любой понравившийся набор данных для задачи классификации из следующего списка:

1. car <https://www.openml.org/d/40975>
2. vehicle <https://www.openml.org/d/54>
3. wine <https://www.openml.org/d/187>
4. bridges <https://www.openml.org/d/327>

Сведение к задаче регрессии и обработка данных

Перейдите от задачи классификации к задаче регрессии, используя [OneHot преобразование](#). Вместо одного целевого признака в выбранный набор данных добавляется столько новых числовых переменных, сколько в нём содержится классов. Помимо этого, если выбранный Вами набор данных содержит нечисловые признаки, эти признаки необходимо векторизовать (перейти от категорий к числам), заполнить пропуски (если есть) и нормализовать. В наборе данных bridges также необходимо избавиться от столбца IDENTIF, поскольку он является идентификатором записи.

Реализация алгоритма и настройка гиперпараметров, анализ результатов

Реализуйте алгоритм решения задачи непараметрической регрессии при помощи ядерного сглаживания Надарая-Ватсона.

Найдите лучшую комбинацию гиперпараметров алгоритма непараметрической регрессии:

- функция расстояния:
 - расстояние Евклида,
 - расстояние Манхэттена,
 - расстояние Чебышева;
- функция ядра
 - uniform: $K(u) = \frac{1}{2}$
 - triangular: $K(u) = (1 - |u|)$
 - epanechnikov: $K(u) = \frac{3}{4}(1 - u^2)$
 - quartic: $K(u) = \frac{15}{16}(1 - u^2)^2$
- тип окна (окно, зависящее от количества соседей и фиксированное)
- параметр окна:
 - количество ближайших соседей от 1 до $\sqrt{|D|}$, $|D|$ — размер набора данных, $\sqrt{|D|}$ является эвристикой на число ближайших соседей для метрических алгоритмов **ИЛИ**
 - размер окна, его необходимо выбирать исходя из “размеров” набора данных; хорошей практикой является настройка ширины окна на отрезке $[\frac{R(D)}{\sqrt{|D|}}; R(D)]$ с шагом $R(D) / \sqrt{|D|}$, где $R(D)$ — самое большое расстояния между элементами в наборе данных.

Таким образом требуется перебрать $24\sqrt{|D|}$ комбинаций гиперпараметров и найти лучшую.

Используйте Leave-One-Out перекрёстную проверку для настройки алгоритма.

Критерием качества является F-мера. Для её подсчёта потребуется определить максимальную компоненту результирующего вектора целевых признаков, полученных из One-Hot преобразования, после применения очередной конфигурации алгоритма непараметрической регрессии (алгоритм с одной из комбинаций гиперпараметров).

Для лучшей найденной комбинации гиперпараметров постройте графики зависимости F-меры от числа ближайших соседей **или** ширины окна (при фиксированных лучших значениях прочих гиперпараметров).

Схема работы

